

基于多源特征工程与稳健融合的加密货币市场预测模型研究

摘要

加密货币市场短期收益预测具有信号弱、噪声高、特征维度高和分布不稳定等特点。本文以 Kaggle DRW Crypto Market Prediction 任务为研究对象，基于 DRW 提供的生产特征数据预测加密货币未来短期价格变动相关目标，官方评价指标为预测值与真实标签之间的 Pearson correlation。原始训练集包含 525886 行样本、785 个数值特征和目标列 `label`，测试集包含 538150 行样本。由于特征高度匿名且存在明显冗余，本文构建了一套从线性基线、特征筛选、稳健验证、结构化特征工程到低权重非线性信号融合的完整建模流程。

实验首先验证了 Ridge 等线性模型在高维金融特征上的强基线作用，并通过 Pearson top-k 和 Spearman top-k 筛选获得稳定提升。随后，本文引入 correlation medoid、SHAP-stable XGBoost、symbolic interaction features、supervised AutoEncoder 和 supervised MLP 等多类互补信号，并通过小权重融合缓解单一模型在 public/private 分布差异下的过拟合风险。最终模型采用多阶段 ensemble 结构；开发阶段日志中该冻结 Beta7 文件记录 private `0.10550`，赛后复核同一最终文件得到 public `0.06547`、private `0.11043`。由于复核提交发生在比赛结束后，本文不声称官方排名；按整理的最终榜单分数静态插入，其 private 分数约落在第 6 位、public 分数约落在第 514 位。实验表明，该任务的关键不在于盲目增加模型复杂度，而在于对高维匿名特征进行稳定筛选、构造可转移的新信号，并在 public/private 偏差下采取保守融合策略。

关键词：加密货币预测；Pearson correlation；Ridge 回归；特征工程；模型融合；稳健验证

1. 问题背景与任务定义

1.1 金融短期预测的建模困难

金融市场短期收益预测通常属于弱信号预测问题。与图像、文本等任务相比，市场数据中的目标信号往往被大量噪声覆盖，且特征与标签之间的关系可能随时间变化而漂移。加密货币市场具有交易活跃、波动剧烈、结构快速变化等特点，因此模型不仅需要在训练样本上获得较高相关性，还必须具备对隐藏测试分布的泛化能力。

本任务中的大部分特征为匿名变量，除 `bid_qty`、`ask_qty`、`buy_qty`、`sell_qty`、`volume` 等少数可命名市场特征外，其余特征以 `x1-x780` 的形式给出。这意味着建模过程中无法依赖明确的业务语义解释每个特征，而必须更多依靠统计相关性、特征冗余结构、时间稳定性和模型输出行为进行判断。

此外，Kaggle 比赛通常包含 public leaderboard 和 private leaderboard。public 分数只基于测试集的一部分，private 分数基于隐藏测试集的另一部分。若模型过度追逐 public 分数，可能出现 public 提升而 private 下降的情况。因此，本文特别关注模型在不同验证口径下的稳定性，并将 public/private divergence 作为模型分析的重要部分。

1.2 任务目标与评价指标

本任务的目标是对测试集中每个样本生成一个连续预测值 `prediction`，使其与隐藏真实标签 `label` 的 Pearson correlation 尽可能高。该目标与 Kaggle 官方 overview 中“预测加密货币未来短期价格变动”的任务描述一致 [1]。

Pearson correlation 的定义为：

$$\rho(y, \hat{y}) = \frac{\sum_{i=1}^n (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^n (\hat{y}_i - \bar{\hat{y}})^2}}$$

其中， y_i 表示真实标签， $\hat{y}_i$ 表示模型预测值， $\bar{y}$ 和 $\bar{\hat{y}}$ 分别表示真实值和预测值均值。

与 RMSE 不同，Pearson correlation 更关注预测值与真实值之间的线性相关方向，而不直接惩罚预测值的绝对尺度偏差。这一特点对模型选择产生了重要影响：部分模型在 RMSE 或本地 holdout 上表现较好，但并不一定能在 leaderboard 上获得更高 Pearson 分数。因此，本文在实验中同时记录 holdout Pearson、RMSE、public 分数和 private 分数，并重点分析它们之间的不一致。

1.3 项目简介与技术路线

本项目以官方预测任务为主任务，并围绕该任务补充三个扩展分析问题。主任务关注如何构建可提交的短期收益预测模型；扩展任务 1 从输入端分析高维匿名特征的冗余结构和降维筛选效果；扩展任务 2 从验证端分析模型在不同 row-order time segment 上的稳定性和 public/private 分歧；扩展任务 3 从输出端解释最终预测值是否具有排序和方向含义。三类扩展分别对应“输入特征是否可靠”“验证结论是否稳定”和“模型输出是否可解释”，共同服务于主问题的建模可信度。

仓库实现采用共享代码结构：`src/drw_crypto/` 保存数据读取、预处理、指标、验证和特征工程等复用模块；`scripts/` 保存各阶段实验入口；`configs/` 保存可复现实验配置；`runs/` 保存验证预测、指标表和中间产物；`submissions/` 保存 Kaggle 提交文件；`reports/figures/` 保存报告图表。整体技术路线可概括为：

```
数据读取与 schema 校验
-> 训练段拟合的缺失值填充和标准化
-> 时间顺序验证与 rolling validation
-> Ridge/LightGBM/XGBoost/CatBoost 基线
-> Pearson/Spearman/SHAP/interaction 特征构造
-> AE/MLP 非线性补充信号
-> 多阶段小权重融合
-> public/private 分析和预测信号解释
```

该结构保证了主任务、扩展任务和报告图表均可追溯到对应脚本与实验产物，而不是只基于单次手工提交结果。

2. 数据与预处理

2.1 数据结构

本项目使用 Kaggle DRW Crypto Market Prediction 官方数据集。官方任务说明要求参赛者基于 DRW 的生产特征数构建模型，以预测加密货币未来短期价格变动 [1]。数据文件包括训练集、测试集和提交样例文件。

数据文件	行数	列数	说明
train.parquet	525886	786	785 个特征 + label
test.parquet	538150	786	测试特征，提交时按样例文件对齐
sample_submission.csv	538150	2	包含 ID 和 prediction 两列

训练集中，label 为目标列，其余数值列作为候选特征。测试集中的 label 为占位或不可用信息，不参与建模。最终提交文件需保持与 sample_submission.csv 中的 ID 顺序一致。

2.2 预处理策略

本文采用统一的表格数据预处理流程：

- 1. 仅使用数值特征；
- 2. 排除目标列 label 和提交标识列 ID ；
- 3. 缺失值使用训练 split 的中位数填充；
- 4. 数值特征使用训练 split 的均值和标准差进行标准化；
- 5. 所有特征筛选、top-k 排名、interaction scoring、AE/MLP 训练均只在训练部分拟合，避免验证集信息泄露。

对于 Ridge、XGBoost、MLP 等不同分支，预处理器均在对应训练数据上单独拟合，然后应用于验证集或测试集。这样可以保证实验比较的可复现性和防泄露性。

2.3 验证切分与泄露控制

主验证口径采用 row-order chronological split，即按原始行顺序将前 80% 样本作为训练集，后 20% 样本作为 holdout 验证集：

$$D_{\text{train}} = D_{1:[0.8n]}, \quad D_{\text{valid}} = D_{[0.8n]+1:n}$$

这一切分方式保留了样本的时间顺序假设，避免随机切分带来的潜在时间泄露。对于部分需要更强稳定性分析的分支，本文进一步使用 rolling validation 和 purged group time split。例如，在 SHAP-stable XGBoost 和 Sprint-A interaction stability 中，训练集被划分为多个连续 group，并在验证某一 group 时剔除相邻 group，以降低邻近时间样本带来的泄露风险。

3. 基线建模

3.1 全特征基线

首先，本文在全部原始数值特征上训练 Ridge、LightGBM 及二者的加权融合模型，作为未经特征筛选的基础对照。

Ridge 回归的目标函数为：

$$\min_{\mathbf{w}} \left\{ \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \mathbf{w})^2 + \alpha \|\mathbf{w}\|_2^2 \right\}$$

其中， α 为正则化强度。较大的 α 会压缩模型参数，降低过拟合风险。

全特征基线的 holdout 结果如下：

模型	Holdout Pearson
Full Ridge	0.097166
Full LightGBM	0.063721
Full Ridge + LightGBM	0.100263

结果显示，Ridge 明显强于单独 LightGBM，说明该任务中存在较强的线性相关结构。直接使用树模型并未取得优势，可能是由于原始特征维度高、冗余强且噪声较多。因此，后续实验不再简单追求复杂模型，而是首先围绕特征筛选与信号构造展开。

3.2 Pearson top-k Ridge

为了降低高维匿名特征中的冗余和噪声，本文首先使用 train-only Pearson correlation 对特征排序。对每个特征 x_j ，计算其与标签 y 的绝对 Pearson 相关系数：

$$s_j = |\rho(x_j, y)|$$

然后选择排名前 k 的特征训练 Ridge 模型。实验比较了 top50、top100、top200、top300、top500 以及 full feature 等不同宽度。

该阶段的关键发现为：

模型分支	Public	Private	说明
top100 Ridge	0.03716	0.08901	单一 top100 Ridge 信号
top50/top100 Ridge blend	0.04652	0.09280	top50 与 top100 互补
high-alpha top50/top100 blend	0.05160	0.09638	Beta2 最优线性基线

从 leaderboard 结果看，早期 Baseline1 的 stability blend private 仅为 0.06628，而 Beta1 中单一 top100 Ridge 信号已经提升到 0.08901。这个对比说明，后续提升并不是来自简单模型堆叠，而是来自对高维匿名特征的重新筛选：去掉大量冗余特征后，线性模型反而更容易捕捉可转移信号。

Pearson top-k Ridge 的提升说明，原始 785 个特征中存在大量冗余和噪声。通过简单的相关性筛选，模型不仅更稳定，而且在 private leaderboard 上显著优于未经筛选的模型。Beta1 到 Beta2 的进一步提升则来自 top50/top100 组件互补和 Ridge 正则化强度调节，为后续 Spearman、SHAP-stable、interaction 等信号提供了主干。

4. 特征筛选与稳健性探索

4.1 Spearman top-k 信号

Pearson correlation 衡量线性关系，而 Spearman correlation 衡量排序关系。对于金融数据，特征与收益之间的关系可能并不严格线性，而表现为更弱的单调或排序信号。因此，本文进一步使用 Spearman top-k 特征筛选构造新的 Ridge 信号。

Spearman top50 Ridge 以小权重加入 Pearson Ridge stack 后，private 分数提升到 0.10003。后续权重微调显示，Spearman signal 在 0.225 到 0.235 附近形成 private plateau，继续增加权重会导致 private 回落。

这一结果说明，Spearman top50 与 Pearson top50/top100 不是完全同质的信号，它补充了排序维度的信息。但该分支很快进入局部平台，继续做同轴权重微调收益有限。

4.2 残差筛选与滚动稳定性

为了进一步寻找互补信号，本文尝试了 residual feature selection 和 rolling-stability-aware feature selection。

Residual selection 的思想是先用当前最优模型得到训练集预测 $\hat{y}$ ，再计算残差：

$$r_i = y_i - \hat{y}_i$$

然后寻找与残差 r 高相关的特征，希望捕捉当前模型尚未解释的信息。rolling-stability-aware selection 则将训练集按时间顺序分段，寻找在多个时间窗口中相关性较稳定的特征。

实验结果显示，这两类方法在本地 holdout 或 public leaderboard 上有时能取得改善，但 private 转移不稳定。特别是残差信号权重较高的融合往往带来 public 提升但 private 下降。这说明，在该任务后期，简单追求本地残差或局部稳定性并不能保证隐藏测试集泛化。

4.3 Correlation medoid 与 SHAP-stable XGBoost

受高分方案启发，本文进一步尝试从特征冗余结构出发构造新的信号。首先计算 feature-feature correlation，并以 $1 - |\rho(x_i, x_j)|$ 作为距离，对高度相关特征进行聚类。每个 cluster 中选取 medoid feature，即与同 cluster 其他成员绝对相关性总和最高的特征，作为该特征簇的代表。

单独使用 medoid features 训练 Ridge 并未取得理想结果：

分支	Public	Private	结论
Medoid Ridge blend	0.05437	0.09565	直接作为信号不转移
SHAP-stable XGB blend	0.05634	0.10043	小幅真实提升

虽然 medoid Ridge 作为直接信号失败，但 medoid features 为后续 XGBoost + SHAP 稳定筛选提供了更干净的输入空间。本文在 purged group folds 中训练 XGBoost，并利用 TreeSHAP 提取各 fold 的重要特征，再选择在多个 fold 中稳定出现的特征。基于这些特征训练的 SHAP-stable XGBoost 小权重加入后，将 private 分数从 0.10003 提升到 0.10043。这是本文第一个有效的非线性/树模型补充信号。

5. 符号交互特征工程

5.1 交互特征生成与筛选

在特征筛选的基础上，本文进一步构造 symbolic interaction features。基础特征池由以下特征组成：

- 1. SHAP-stable features；
- 2. Spearman top50 中排名靠前的特征；

3. Pearson top50/top100 中排名靠前的特征。

去重后，核心特征池控制在 40 个特征左右。对于任意两个核心特征 x 和 y ，生成如下二阶 interaction：

$$x + y, \quad x - y, \quad x \cdot y, \quad \frac{x}{|y| + \epsilon}, \quad \frac{y}{|x| + \epsilon}, \quad \max(x, y), \quad \min(x, y)$$

其中， $\epsilon = 10^{-6}$ 用于避免除零问题。




图 1 特征工程漏斗

图 1 展示了主任务中的特征空间变化：原始 785 个可用特征先被压缩为 40 个核心特征，再生成 5460 个二阶 interaction 候选，最终筛选出 120 个 interaction features，并与 40 个 core features 共同构成 160 维结构化输入。该过程体现了本文的核心建模思路：不是直接扩大模型输入，而是在受控候选空间中构造可解释、可筛选的新特征。

生成的候选 interaction 通过以下 train-only 分数筛选：

1. 与标签的绝对 Pearson correlation；
2. 与标签的抽样 Spearman correlation；
3. 与当前最优模型残差的绝对 Pearson correlation；
4. 候选特征之间的高相关去重。

最终保留 120 个 interaction features，分别训练 Ridge 和 XGBoost，并与当前最优模型进行小权重融合。




图 2 入选 interaction 操作类型分布

图 2 展示了最终 120 个 selected interaction features 的操作类型分布。不同操作类型共同入选，说明有效 interaction 并不只来自单一乘法或比值形式，而是来自多种二阶组合对原始匿名特征的补充表达。

5.2 Interaction Ridge 结果

Interaction 分支带来了本文最大的一次结构性提升。

分支	Public	Private	结论
XGB interaction blend	0.05657	0.10044	基本持平
Ridge interaction-only blend	0.06362	0.10302	最大结构性提升

结果表明，interaction features 确实补充了原始 top-k 信号。值得注意的是，XGBoost 在 interaction 特征上并不强，真正有效的是 Ridge interaction-only signal。这说明，在经过手工构造的 interaction 空间中，线性模型能够稳定捕捉一部分新的可转移结构，而更复杂的树模型反而容易引入噪声。

5.3 交互特征精调与边界

为验证 interaction 分支是否仍有空间，本文进一步进行了 Beta5-B 和 Sprint-A。Beta5-B 将 interaction 数量扩展到 240，并提高 interaction signal 权重；Sprint-A 则用 purged fold-stable scoring 重新筛选 interaction features。

代表性结果如下：

Candidate	Public	Private
240 interactions, weight 0.20	0.06797	0.10256
Sprint-A top250_min3_fill120, weight 0.05	0.06637	0.10514

Candidate	Public	Private
Sprint-A top250_min4_fill120, weight 0.15	0.06766	0.10437

这些结果说明，interaction 方向确实有效，但简单扩大 interaction 数量或提高权重会更多追逐 public/holdout，而不一定改善 private。最终本文保留 Beta5-A 的 120 interaction Ridge blend 作为主线组件。

6. 表征学习与神经网络信号

6.1 AutoEncoder 表征特征

为了测试低维表征学习是否能进一步提取隐藏结构，本文在 40 个 core features 和 120 个 selected interactions 的 160 维结构化输入上训练 AutoEncoder。模型将输入压缩到 8、16 或 32 维 bottleneck，并尝试了 denoising 和 supervised auxiliary head。

无监督 AE 的结果不理想。虽然部分 AE signal 能提升 holdout/public，但 private 明显下降。

分支	Public	Private	结论
AE ridge, weight 0.15	0.06488	0.10169	private 下降
AE ridge, weight 0.10	0.06454	0.10225	仍低于当前候选
supervised AE8, weight 0.025	0.06454	0.10303	极小提升

后续实验显示，扩大 bottleneck、加入轻度 denoising 或更换 seed 都没有改善 private。将 AE 改为 supervised AE，即在重构输入的同时用 latent representation 辅助预测标准化目标，能产生极弱但可转移的信号。最终 supervised AE8 只以 0.025 的极小权重加入模型。

这说明，AE representation 在当前实现下不能作为主力信号，只能作为非常保守的辅助组件。

6.2 Supervised MLP 信号

在 AE 之后，本文进一步训练 supervised MLP。MLP 输入仍为 160 维结构化特征，网络结构包括 [256,128,64] 和 [128,64,32] 两类隐藏层设置，优化器比较了 SGD 和 AdamW。损失函数为 MSE 与 Pearson loss 的加权组合：

$$\mathcal{L} = 0.6 \cdot \text{MSE}(y, \hat{y}) + 0.4 \cdot (1 - \rho(y, \hat{y}))$$

其中，

$$\text{MSE}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

MLP 的定位不是替代当前最优模型，而是生成低权重非线性互补信号。

关键结果如下：

Candidate	Public	Private	结论
AdamW seed mean, weight 0.025	0.06588	0.10411	保守提升
AdamW seed2026, weight 0.075	0.06553	0.10550	开发阶段记录
AdamW seed2026, weight 0.075	0.06547	0.11043	同一冻结文件赛后复核最优观测
AdamW seed3026, weight 0.10	0.06930	0.10304	public 高但 private 低

后续 Sprint-B 对 AdamW MLP 进行 seed stability 检查，结果显示新 seed 和 seed mean 均未复现 seed2026 的 private 增益。因此，MLP 分支虽然有效，但具有 seed sensitivity。最终模型保留 `wide_adamw_lr001_seed2026` 的 0.075 小权重，而不是使用多 seed 平均。

7. 最终模型与融合策略

7.1 最终模型结构

最终模型不是单一模型，而是由多阶段互补信号逐步叠加得到。其结构可以写成如下递推形式：

$$\begin{aligned} \text{beta3} &= 0.3825 \cdot \text{top50_ridge}_{\alpha=200000} + 0.3825 \cdot \text{top100_ridge}_{\alpha=50} + 0.2350 \cdot \text{spearman_top50_ridge} \\ \text{beta4} &= 0.75 \cdot \text{beta3} + 0.25 \cdot \text{shap_stable_xgboost} \\ \text{beta5} &= 0.85 \cdot \text{beta4} + 0.15 \cdot \text{ridge_interactions_only} \\ \text{beta6_2} &= 0.975 \cdot \text{beta5} + 0.025 \cdot \text{supervised_ae8_ridge} \\ \text{final} &= 0.925 \cdot \text{beta6_2} + 0.075 \cdot \text{wide_adamw_mlp_seed2026} \end{aligned}$$




图 3 最终多信号融合结构

图 3 总结了最终模型结构。可以看到，最终预测并不是由单一复杂模型给出，而是由 Ridge top-k 主干、SHAP-stable XGBoost、interaction Ridge、supervised AE 和 supervised MLP 按阶段叠加得到。

同一冻结 Beta7 文件在 Kaggle 赛后复核提交中得到如下最佳观测分数：

指标	分数
Public Pearson	0.06547
Private Pearson	0.11043

Submission and Description		Private Score ⓘ	Public Score ⓘ	Selected
	submission_blend_current_w0p925_wide_adamw_lr001_seed2026_w0p075.csv Complete (after deadline) · 5d ago · Codex probe final beta7 seed2026 w0.075	0.11043	0.06547	☐
	submission_blend_current_w0p9125_wide_adamw_lr001_seed2526_w0p0875.csv Complete (after deadline) · 6d ago · Sprint-B AdamW seed2526 w0.0875	0.10205	0.06397	☐
	submission_blend_current_w0p925_wide_adamw_lr001_seed4026_w0p075.csv Complete (after deadline) · 6d ago · Sprint-B AdamW seed4026 w0.075	0.10321	0.06944	☐
	submission_blend_current_w0p975_adamw_new_seed_mean_w0p025.csv Complete (after deadline) · 6d ago · Sprint-B AdamW new seed mean w0.025	0.10376	0.06573	☐
	submission_top250_min4_fill120_ridge_interactions_w0p15.csv Complete (after deadline) · 6d ago · Sprint-A fold-stable interaction top250 min4 w0.15	0.10437	0.06766	☐
	submission_top250_min3_fill120_ridge_interactions_w0p05.csv Complete (after deadline) · 6d ago · Sprint-A fold-stable interaction top250 min3 w0.05	0.10514	0.06637	☐
	submission_blend_beta6p2_w0p9125_wide_adamw_lr001_seed2026_w0p0875.csv Complete (after deadline) · 6d ago · beta7.1 adamw seed2026 w00875	0.10550	0.06539	☐

Kaggle 赛后提交记录截图

该分数来自比赛结束后的复核提交，提交文件为

`submissions/01_main/beta7_mlp_signal/submission_blend_current_w0p925_wide_adamw_lr001_seed2026_w0p075.csv`。它与开发阶段冻结的 Beta7 最终公式相同，因此不改变主线模型结构，只更新该文件的最佳观测 leaderboard 分数。由于提交发生在赛后，本文不将其写作官方排名；若按整理的最终榜单分数静态插入，其 private 分数约落在第 6 位，public 分数约落在第 514 位。public 与 private 的明显差异说明，最终模型并非以 public leaderboard 为导向的过度适配结果，而是在 hidden private 分布上具有更好的观测表现。

7.2 小权重融合的必要性

本文后期大量实验显示，复杂信号往往存在如下模式：

1. 较大权重能提升 holdout 或 public；
2. private 不一定提升，甚至下降；
3. 小权重互补信号更容易转移到 private。

例如，更大规模 interaction set、较高权重 AE 融合、MLP 0.10 权重以及 Sprint-A/Sprint-B 候选都出现了 public 或 holdout 较好但 private 不如最终候选的现象。因此，最终融合策略不是选择本地最优模型，而是选择已验证的低权重互补信号。

从建模角度看，这一策略相当于将最终预测分解为强主干信号与多个弱补充信号：

$$\hat{y}_{\text{final}} = \sum_{m=1}^M w_m \hat{y}^{(m)}, \quad \sum_{m=1}^M w_m = 1$$

其中， $\hat{y}^{(m)}$ 表示不同信号族的预测， w_m 为融合权重。有效的补充信号不需要单独很强，但需要与主模型存在一定差异，并且在 private 上能提供稳定增益。

8. 实验结果与对比分析

8.1 阶段性结果

主任务最终提升过程如下：

阶段	Public	Private	说明
Baseline1 stability	0.03365	0.06628	早期稳定性融合基准
Beta1 top100 Ridge	0.03716	0.08901	首个强可转移 top-k Ridge 信号
Beta2 Ridge	0.05160	0.09638	强线性 top-k 基线
Beta3 Spearman	0.05456	0.10003	排序相关性特征筛选
Beta4 SHAP-stable XGB	0.05634	0.10043	树模型稳定特征信号
Beta5 Interaction Ridge	0.06362	0.10302	最大结构性提升
Beta6.2 Supervised AE	0.06454	0.10303	极小表征增益
Beta7 MLP 开发记录	0.06553	0.10550	开发阶段冻结记录
Beta7 赛后复核	0.06547	0.11043	同一冻结文件赛后最佳观测




图 4 主任务 private 分数阶梯

图 4 展示了 private 分数从 Baseline1、Beta1 到 Beta7 的逐步提升。早期 Baseline1 到 Beta1 的跃迁强调了特征筛选带来的强对比；后续 Beta2 到 Beta7 的提升则说明最终结果来自多类互补信号的持续累积，而不是某一次模型替换带来的偶然提升。赛后复核点使用同一冻结文件，不代表重新开启了一条新的模型路线。

8.2 Public/private 分歧




图 5 Public 与 private 分数关系

从 public/private scatter 可以看出，public 分数较高的候选不一定 private 更高。例如，部分高权重 MLP、宽 interaction 和 AE 候选在 public 上表现更强，但 private 明显低于最终候选。这说明 public leaderboard 对模型选择存在误导风险，尤其是在后期模型差异较小、候选高度依赖细微信号时。

因此，本文最终不采用 public 最高的候选，而是选择在 private 已验证、且融合权重较保守的模型结构。

8.3 组件相关性与互补性




图 6 验证集组件预测相关性

component correlation heatmap 用于观察不同信号族预测之间的相关性。若所有组件高度同质，则 ensemble 很难带来额外收益；若组件差异过大且单体不稳定，也可能引入噪声。本文最终有效组件大多与主模型存在较高但非完全一致的相关性，说明它们并不是完全独立模型，而是主干信号上的结构性修正。

9. 模型分析与失败实验

9.1 成功信号分析

本文最终保留的主要信号包括：

1. Pearson top-k Ridge：提供强线性基线；
2. Spearman top50 Ridge：补充排序关系；
3. SHAP-stable XGBoost：提供树模型稳定特征信号；
4. symbolic interaction Ridge：提供最大结构性增益；
5. supervised AE8：提供极小表征修正；

6. supervised MLP：提供低权重非线性修正。

其中，interaction Ridge 是后期最重要的结构性提升。它说明，在匿名特征缺乏业务语义的情况下，通过统计筛选得到的二阶组合可以构造出新的有效特征空间。

9.2 失败方向分析

本文没有回避失败实验。主要失败方向包括：

- 1. Full LightGBM 不如 Ridge；
- 2. medoid Ridge 不转移；
- 3. direct residual blend 不稳定；
- 4. SHAP-stable 规则微调未超过原始 Beta4-B；
- 5. 扩大到 240 interaction features 后，public 提升但 private 下降；
- 6. 无监督 AE 和更宽 AE 表征不转移；
- 7. MLP seed mean 不如单个 seed2026；
- 8. 后期 Sprint-A/Sprint-B 均未超过最终候选。




图 7 本地 holdout 提升与 private 提升对比

这些失败实验说明，该任务的模型选择不能只依赖本地 holdout 或 public 分数。许多更复杂、更重的信号会提高局部指标，却降低 hidden private 泛化。

9.3 与第一名方案的差距

本文参考了第一名方案中的若干方法级思想，包括 correlation clustering、SHAP-stable feature selection、symbolic interactions、AE features 和 MLP signals。根据第一名公开 writeup 及评论区说明，其核心流程包括：使用 $1 - |\rho|$ 作为距离对原始特征聚类，在 threshold 0.6 下得到约 60 个 medoid representatives；再删除与目标几乎无关的特征，保留约 40 个特征；使用 6 组 purged group time series split 和 XGBoost TreeSHAP 选择跨 fold 稳定出现的特

征；进一步构造二阶、三阶 symbolic combinations，并进行 feature recycling；最终将特征输入 AutoEncoder 合成 8 个 deep features，并以三层 MLP 作为主要模型 [3]。

本文已经复现了上述路线中的主要方法方向，但没有完全复现第一名的最终效果。差距主要体现在以下方面：

1. 第一名方案的 symbolic feature engineering 更深入，除二阶组合外还包含三阶组合和逐个回收被丢弃特征的 feature recycling；
2. 第一名方案中 MLP 是主模型，单模型 private 可达到约 0.131，而本文 MLP 只能作为低权重补充信号；
3. 第一名方案中 AE features 是重要增益来源，而本文 AE features 没有形成独立强表征；
4. 第一名本地 CV 虽然整体高于 leaderboard，但候选提升与 public leaderboard 的相关性较稳定；本文后期本地验证、public 分数和 private 分数之间存在更明显错位；
5. 第一名方案在特征筛选、组合生成、表征学习和验证反馈之间形成了更深的迭代闭环，而本文的迭代深度有限。

因此，本文的主要贡献不是完全复现第一名，而是在有限时间内构建了一条可复现、可解释、可分析的建模路线，并系统验证了哪些信号能够转移到 private，哪些方向只是局部验证或 public 指标上的泛化不稳定方向。

10. 扩展任务 1：高维匿名特征的筛选与降维分析

10.1 问题定义与边界

扩展任务 1 回答的问题是：在大量匿名、高相关、可能冗余的特征存在时，如何通过特征筛选或降维，在减少维度和保持预测能力之间取得平衡。

本扩展任务不参与最终 Kaggle 模型选择，也不替换第 7 节中的冻结 Beta7 最终文件。这里的目标是分析高维匿名特征空间的冗余结构，并比较不同压缩策略在特征数量、holdout Pearson、RMSE、训练成本和解释性之间的权衡。所有筛选、PCA、聚类、ElasticNet、LightGBM importance 和 SHAP ranking 均只在 chronological outer train split 上拟合；outer holdout 仅用于最终评估。

10.2 匿名特征冗余结构

在 outer train split 上，本文计算了 785 个原始数值特征之间的绝对 Pearson correlation。共有 307720 个特征对，绝对相关系数均值为 0.122248，中位数为 0.061925，但尾部相关性很强：95% 分位数达到 0.448159，99% 分位数达到 0.733853。其中，绝对相关系数不低于 0.7 的特征对有 3785 对，不低于 0.9 的有 1071 对，不低于 0.95 的仍有 425 对。




图 8 匿名特征相关性分布

该结果说明，虽然多数特征对相关性较低，但存在大量高度冗余的局部特征簇。若直接使用全部特征，模型需要同时处理弱信号、噪声和冗余变量；若压缩过强，又可能丢失与目标相关的少量有效信号。因此，扩展任务 1 的核心不是简单追求最低维度，而是寻找压缩率和预测保持能力之间的折中。




图 9 相关性聚类的簇大小分布

10.3 筛选与降维实验

本文比较了 full features、Pearson top-k、Spearman top-k、PCA、相关性聚类代表特征、相关性聚类簇均值、ElasticNet、LightGBM importance top-k 和 SHAP top-k。除 ElasticNet 直接使用自身模型评估外，其余特征方案均使用 Ridge alpha search 在同一 outer holdout 上评估。

各方法的最佳结果如下：

方法	最佳方案	维度	Holdout Pearson	RMSE
Pearson top-k	top200	200	0.124899	1.081521
Spearman top-k	top50	50	0.103647	1.051488
Full features	all features	785	0.097166	1.235401
相关性聚类代表特征	threshold 0.6	125	0.097382	1.105280
相关性聚类簇均值	threshold 0.6	126	0.091806	1.115458
SHAP top-k	top300	300	0.090262	1.184801
ElasticNet	full features	785	0.088555	1.178551
LightGBM importance top-k	top200	200	0.086887	1.136761
PCA	200 components	200	0.085799	1.110787




图 10 维度数量与 holdout Pearson 的关系

结果显示，Pearson top200 在本实验中取得最高 holdout Pearson，明显高于 full-feature Ridge。这说明原始 785 个特征中确实存在较多冗余和噪声，监督式相关性筛选可以提升线性模型的有效信噪比。Spearman top50 只保留

50 个特征，Pearson 仍超过 full features，也说明排序相关性能够捕捉一部分与 Pearson 不完全相同的信号。

PCA 在 200 个主成分下已保留约 97.64% 的训练特征方差信息，但 holdout Pearson 仅为 0.085799，低于 Pearson top-k 和 full features。这说明，无监督方差压缩并不一定保留目标相关信号；在弱信号金融预测中，“方差最大”的方向未必就是“预测最有用”的方向。




图 11 各方法最佳 holdout Pearson 对比

10.4 模型驱动筛选对比

为比较模型驱动筛选与简单相关性筛选，本文在 outer train 内部再次划分 inner train/inner validation，训练 full-feature LightGBM，并基于 gain importance 和 TreeSHAP mean absolute value 得到两组特征排名。随后只使用这些排名产生 top-k 特征集，再回到统一的 Ridge outer-holdout 评估口径。

LightGBM importance 的最佳结果为 top200，holdout Pearson 为 0.086887；SHAP ranking 的最佳结果为 top300，holdout Pearson 为 0.090262。二者都低于 Pearson top200 的 0.124899。这并不说明 LightGBM 或 SHAP 没有价值，而是说明在本任务的简单特征筛选层面，树模型重要性排名更容易捕捉 inner split 的局部非线性结构，不一定比 train-only target correlation 更适合作为 Ridge 的基础输入。




图 12 相关性筛选与模型驱动筛选的 top-k 对比

10.5 压缩率与预测能力权衡

从压缩率角度看，Pearson top200 将特征数量从 785 降到 200，压缩约 74.5%，同时 holdout Pearson 从 full-feature Ridge 的 0.097166 提升到 0.124899。相关性聚类代表特征在 threshold 0.6 下只保留 125 个代表特征，Pearson 为 0.097382，与 full-feature Ridge 基本相当，但 RMSE 明显低于 full-feature Ridge。这说明去冗余可以显著压缩输入空间，但未必能最大化 Pearson。




图 13 特征压缩率与预测能力权衡

对主任务的启示是：高维匿名特征不能简单全部输入模型，监督式筛选能显著改善 Ridge 的有效信号质量；PCA、聚类、ElasticNet、LightGBM importance 和 SHAP 各自提供了不同视角，但它们更适合作为结构分析和辅助筛选工具，而不是直接替代最终多信号融合模型。最终主任务采用 top-k 线性主干、结构化 interaction 和小权重非线性补充，正是因为特征压缩、冗余控制和预测保持之间存在这种权衡。

11. 扩展任务 2：时间稳定性与分布漂移分析

11.1 Rolling validation 设计与结果

为检验模型在不同时间段上的稳定性，本文在主线建模之外构造了 expanding rolling validation。每个 fold 使用从样本开头开始的连续训练段，并在后续相邻时间段上验证：

Fold	训练区间	验证区间
fold_50_60	0%-50%	50%-60%
fold_60_70	0%-60%	60%-70%
fold_70_80	0%-70%	70%-80%
fold_80_90	0%-80%	80%-90%

每个 fold 内重新进行 train-only Pearson 特征排序、缺失值填充、标准化、Ridge/LightGBM 训练和 Ridge-LightGBM 融合。该设计避免了随机 K-fold 可能引入的时间泄露，也能观察模型表现是否随 row-order time segment

改变。

Rolling validation 的 Ridge-LightGBM ensemble 汇总如下：

Scheme	Mean Pearson	Std	Min	Max	Mean RMSE
top300	0.162315	0.051951	0.103448	0.239494	1.023193
top200	0.153862	0.073044	0.081128	0.272860	1.025452
top500	0.139575	0.036829	0.090258	0.175179	1.044568
top100	0.135306	0.058504	0.079048	0.233110	1.025695
top50	0.121328	0.035865	0.078946	0.170520	1.032792
full	0.115468	0.019837	0.098538	0.147126	1.056822




图 14 Rolling validation 中不同特征方案的 Pearson 波动

图 14 和表格说明，top300 的平均 rolling Pearson 最高，但 top200/top300 也有明显 fold-to-fold 波动；full feature 方案平均分最低，但标准差最小。也就是说，最高 rolling mean 并不等于最稳健模型。本文后续采用小权重融合，而不是简单选择 rolling mean 最高的分支，正是因为后期模型排序在不同验证口径下并不稳定。

11.2 目标分布漂移

各验证时间段的目标分布如下：

Fold	Target mean	Target std	q05	Median	q95
fold_50_60	0.023199	0.945710	-1.305820	0.013257	1.327380
fold_60_70	0.117703	1.044563	-1.229271	0.059195	1.611012
fold_70_80	0.054910	1.003248	-1.476842	0.042353	1.649716

Fold	Target mean	Target std	q05	Median	q95
fold_80_90	-0.002802	1.029727	-1.430521	-0.002125	1.490496




图 15 不同验证时间段的目标均值与标准差

fold_60_70 的目标均值和上分位数明显抬升，而 fold_80_90 的均值回落到接近 0。这说明目标变量本身随时间段变化，数据不能被简单看作同分布随机样本。由于原始数据没有提供可直接解释的真实时间戳，本文只将其表述为 row-order time segment 上的 distribution drift 或 regime-like shift，不声称已经识别具体市场状态。

11.3 特征选择稳定性与特征漂移

不同 rolling folds 中 top-k 特征集存在一定重叠，但并非完全一致：

Scheme	Mean Jaccard	Min Jaccard	Mean overlap ratio	Min overlap ratio
top50	0.628933	0.492537	0.766667	0.660000
top100	0.675493	0.587302	0.803333	0.740000
top200	0.725838	0.652893	0.839167	0.790000
top300	0.746621	0.690141	0.853889	0.816667
top500	0.770395	0.703578	0.869333	0.826000




图 16 Rolling folds 间特征选择重叠度

top100 中有 63 个特征在 4 个 folds 中都被选中，说明可用信号并非完全随机。但 top100 的最小 Jaccard 只有 0.587302，top50 的最小 Jaccard 进一步降到 0.492537，说明特征重要性仍会随训练时间段变化。

本文进一步选取 top100 中跨 4 个 folds 出现、平均排名最高的 10 个稳定特征，计算其在各验证段相对 0%-50% 参考训练段的均值漂移：

$$z_{\text{mean}} = \frac{\mu_{\text{segment}} - \mu_{\text{reference}}}{\sigma_{\text{reference}}}$$




图 17 稳定特征在不同时间段的均值漂移

图 17 显示，即使是跨 fold 稳定入选的特征，也存在最高约 1.15 个参考标准差的均值偏移。这类特征分布变化会影响 Pearson 排名、模型系数和树模型分裂行为，从而解释为什么同一模型结构在不同时间段上的表现会产生波动。

11.4 Embargo 对照

为检查相邻样本是否导致过于乐观的验证估计，本文增加了一个轻量 embargo 对照。该实验只使用固定 $\alpha = 1000$ 的 Ridge top50/top100/top300，不进行 LightGBM 网格或新的模型选择。对比设置为：

- 1. gap=0：普通 chronological 80/20；
- 2. gap=1% rows：训练集末端与验证集开头之间剔除 5258 行作为 embargo。

结果如下：

Scheme	Gap	Pearson	RMSE	Delta vs gap=0
top50	0.00	0.099189	1.064541	0.000000
top50	0.01	0.115455	1.063095	0.016266
top100	0.00	0.114887	1.071233	0.000000
top100	0.01	0.113566	1.068080	-0.001322
top300	0.00	0.089505	1.151837	0.000000
top300	0.01	0.092602	1.142794	0.003097




图 18 固定 alpha Ridge 的 embargo 对照

Embargo 后 top100 略降，但 top50 和 top300 反而上升。因此，当前证据不支持把验证不稳定简单归因于相邻时间样本泄露。更合理的解释是：不同 row-order segment 的目标分布、特征分布和有效信号强度同时发生变化，导致验证分数随时间段改变。

11.5 Public/private 分歧的解释

主线实验中，public 和 private 分数出现了明显错位。整理 21 个代表性提交后，public/private 分数相关系数约为 0.679，说明二者不是完全无关，但也远非可靠的一一对应。以赛后复核的同一冻结 Beta7 最终文件为参照，有 8 个候选的 public 高于最终文件但 private 低于最终文件。

Candidate	Public	Private	Public rank	Private rank
Sprint-B seed4026	0.06944	0.10321	1	7
Beta7 MLP 高权重候选	0.06930	0.10304	2	8
Beta5B int240	0.06797	0.10256	3	11
Sprint-A w0.15	0.06766	0.10437	4	4
Sprint-A w0.05	0.06637	0.10514	5	3
Beta7 MLP mean	0.06588	0.10411	6	5
Sprint-B mean	0.06573	0.10376	7	6
Beta7 MLP 开发记录	0.06553	0.10550	8	2




图 19 Private 相对 public 分数差较大的提交

进一步地，本文使用整理后的最终 leaderboard 数据检查全体队伍的 public/private 关系。该表包含 1091 个队伍；剔除 4 行 publicScore=-1/privateScore=-1 的异常分数记录后，有效分数行为 1087 行，public/private 分数相关系数为 0.786；public/private 排名相关系数为 0.771。也就是说，分数整体仍同向，但排序会出现明显重排。public 前

20 名队伍的平均 private rank 为 228.85，其中 13 个队伍的 private rank 低于第 100 名；private 第一名的 public rank 为第 37 名。该结果支持“public 分数不能直接代表 private 泛化”的判断，但不等价于证明 public split 或 private split 对应某个具体市场阶段。




图 20 最终榜单 public/private 分数关系

图 20 中，Not_Null 是最终榜单中的公开行，public/private 为 0.08451/0.06553，提交次数为 12。赛后复核的 Beta7 最终文件 public/private 为 0.06547/0.11043，不在官方最终排名中；若按分数静态插入整理后的榜单，其 public 约第 514，private 约第 6。这个对照不能写作官方排名，但能说明同一模型在两个隐藏 split 上可能呈现完全不同的相对位置。




图 21 最终榜单 public/private 排名关系

这种现象可以从三个层面解释。第一，Kaggle public 和 private 是两个不同隐藏 split；若两个 split 对应不同时间段或不同分布，则 public 排名和 private 排名自然可能不一致。第二，public leaderboard 可被多次提交间接适配，后期候选容易奖励 public-specific 的细微信号；本项目通过 Kaggle CLI 可见赛后提交记录共 50 次，而最终榜单中的 `Not_Null` 行只对应赛前/赛中记录的 12 次提交。第三，本文中高权重 MLP、宽 interaction、高权重 AE 等候选多次出现 public 或 holdout 提升但 private 下降，说明更强、更重的局部信号可能只适合某个测试子分布，而不一定适合 private split。

因此，本文不把 public 高低作为最终模型选择的唯一依据。最终模型 public 分数并不突出，但 private 分数最高，说明它更可能贴合 private split 的隐藏分布。需要强调的是，这只是基于提交结果和时间段验证模式作出的 split-level distribution mismatch 推断，不能据此把 public split 或 private split 直接绑定到某一段外部行情。

对主任务的启示是：时间段验证和 public/private 分歧共同说明，后期模型选择不能只依赖单一验证口径。因此，本文在最终模型中采用多类弱互补信号的小权重融合，并保留失败实验分析，以降低对某一个局部 split 的过度适配风险。

12. 扩展任务 3：预测信号解释

12.1 重构验证预测与分析口径

扩展任务 3 的目标是把最终预测值解释为可理解的排序信号，而不是重新选择模型。分析对象仍为冻结 Beta7 公式：

```
final = 0.925 * beta6_2_current_best + 0.075 * wide_adamw_lr001_seed2026
```

由于已有 `wide_adamw_lr001_seed2026` 验证预测文件不是完整 80/20 holdout 长度，本文只重训该单一 MLP 分支，并按 Beta7.1 的配置重构 105178 行 chronological holdout 预测。重构检查如下：

项目	数值
Holdout 样本数	105178
全局样本起点	420708
全局样本终点	525885
Beta6.2 holdout Pearson	0.119194
MLP signal holdout Pearson	0.089807
Final holdout Pearson	0.121517
历史 Beta7 w0.075 holdout Pearson	0.121517

重构结果与历史记录一致，说明后续解释使用的是最终冻结公式对应的验证集预测。该分析只使用 holdout 标签进行事后解释，不参与训练、调参或模型选择。

12.2 高中低预测组解释

将 holdout 样本按最终预测值从低到高排序，定义 bottom 10%、middle 80% 和 top 10% 三组。三组的平均预测值和平均真实目标如下：

Signal group	样本数	平均预测值	平均真实目标
bottom 10%	10518	-0.446904	-0.129457
middle 80%	84143	-0.057816	0.076691
top 10%	10517	0.380940	0.296690




图 22 不同预测强度组的平均真实目标

结果显示，最高预测组的平均真实目标显著高于最低预测组，top-minus-bottom target spread 为 0.426147。这说明最终预测值虽然无法精确预测单个样本，但在样本排序层面确实包含有效信息。

12.3 十分位排序曲线

进一步将预测值划分为 10 个 deciles，计算每个 decile 的平均真实目标。最低两个 deciles 的平均目标为负，随后随预测分位整体上升，最高 decile 的平均目标达到 0.296690。




图 23 不同预测 decile 的平均真实目标

最终预测与真实目标的 Pearson correlation 为 0.121517 ，Spearman rank correlation 为 0.135729 。Spearman 为正且 decile 曲线整体抬升，说明官方 Pearson 分数背后也对应一定排序能力。换言之，模型输出不是只在数值相关性上有效，也能把样本大致分成更高目标和更低目标的群体。

12.4 方向一致性与理论 top-bottom 诊断

本文进一步计算预测值符号与真实目标符号是否一致。整体 sign agreement 为 53.41% ，top/bottom 10% 强信号组为 55.56% ，高于中间 80% 的 52.87% 。




图 24 不同信号强度下的方向一致率

方向一致率只用于解释预测信号的方向含义，不等同于可执行策略效果。特别是，本任务没有建模交易成本、滑点、延迟、仓位约束、换手率或风险控制，因此不能把该指标解释为投资表现。




图 25 预测信号解释汇总

作为无交易成本诊断，若把 top 10% 看作理论高预测组、bottom 10% 看作理论低预测组，两组平均目标差为 0.426147。该数值只说明预测排序和目标均值之间存在差异，不构成任何可执行交易结论。

对主任务的启示是：最终预测值不仅在 Pearson correlation 指标上为正，也能在 holdout 样本排序层面区分较高目标和较低目标群体。这为模型输出提供了直观解释，但仍不能替代真实交易回测。

13. 总结

本文围绕 Kaggle DRW Crypto Market Prediction 主任务，构建了一个从强线性基线到多信号融合完整预测系统。实验表明，在高维匿名金融特征场景下，Ridge 等简单线性模型在经过严格特征筛选后非常强；复杂模型并不能直接替代线性模型，而应作为低权重互补信号加入。

本文的主要发现包括：

- 1. Pearson/Spearman top-k Ridge 是稳定强基线；
- 2. 高维匿名特征存在明显冗余，Pearson top200 在压缩约 74.5% 特征后仍优于 full-feature Ridge；
- 3. SHAP-stable XGBoost 可提供小幅树模型补充；
- 4. symbolic interaction features 是最大的结构性增益来源；
- 5. AutoEncoder 表征在当前实现下效果有限，仅 supervised AE8 有极小收益；
- 6. supervised MLP 可提供非线性补充，但存在 seed sensitivity；
- 7. public/private divergence 明显，模型选择不能只追 public 或 holdout；
- 8. 时间稳定性和分布漂移解释了验证分数随 row-order segment 改变的现象；
- 9. 最终预测值具备可解释的排序含义，高预测组平均真实目标明显高于低预测组；
- 10. 最终有效策略是多类互补信号的小权重保守融合。




图 26 不同信号族的转移效果总结

最终冻结 Beta7 文件的最佳观测 private 分数为 0.11043。 该结果来自赛后复核提交，因此本文不声称官方排名；若按整理后的最终榜单分数静态插入，private 约落在第 6 位。该结果说明，本文方法虽然未完全复现第一名方案，但已经在隐藏测试集上表现出较强泛化能力。后续若继续扩展，可重点研究更系统的特征回收、更复杂但可控的符号特征构造，以及更稳定的监督式表征学习。

参考文献

- [1] Kaggle. DRW Crypto Market Prediction[EB/OL]. Kaggle Competition, 2025.
<https://www.kaggle.com/competitions/drw-crypto-market-prediction>
- [2] Kaggle. DRW Crypto Market Prediction: Evaluation[EB/OL]. Kaggle Competition, 2025.
<https://www.kaggle.com/competitions/drw-crypto-market-prediction/overview/evaluation>
- [3] Kaggle. DRW solution 1st[EB/OL]. Kaggle Competition Writeup, 2025.
<https://www.kaggle.com/competitions/drw-crypto-market-prediction/writeups/drw-solution-1st>
- [4] Hoerl A E, Kennard R W. Ridge regression: biased estimation for nonorthogonal problems[J]. *Technometrics*, 1970, 12(1): 55-67.
- [5] Zou H, Hastie T. Regularization and variable selection via the elastic net[J]. *Journal of the Royal Statistical Society: Series B*, 2005, 67(2): 301-320.
- [6] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]//*Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York: ACM, 2016: 785-794.
- [7] Ke G, Meng Q, Finley T, Wang T, Chen W, Ma W, Ye Q, Liu T Y. LightGBM: A highly efficient gradient boosting decision tree[C]//*Advances in Neural Information Processing Systems*. 2017, 30: 3146-3154.
- [8] Prokhorenkova L, Gusev G, Vorobev A, Dorogush A V, Gulin A. CatBoost: unbiased boosting with categorical features[C]//*Advances in Neural Information Processing Systems*. 2018, 31.
- [9] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]//*Advances in Neural Information Processing Systems*. 2017, 30.
- [10] Pearson K. On lines and planes of closest fit to systems of points in space[J]. *Philosophical Magazine*, 1901, 2(11): 559-572.
- [11] Jolliffe I T. *Principal Component Analysis*[M]. 2nd ed. New York: Springer, 2002.
- [12] Hinton G E, Salakhutdinov R R. Reducing the dimensionality of data with neural networks[J]. *Science*, 2006, 313(5786): 504-507.
- [13] Goodfellow I, Bengio Y, Courville A. *Deep Learning*[M]. Cambridge: MIT Press, 2016.
- [14] López de Prado M. *Advances in Financial Machine Learning*[M]. Hoboken: Wiley, 2018.
- [15] Kaufman R L, Rosset S, Perlich C, Stitelman O. Leakage in data mining: formulation, detection, and avoidance[J]. *ACM Transactions on Knowledge Discovery from Data*, 2012, 6(4): 1-21.

[16] Bailey D H, Borwein J M, López de Prado M, Zhu Q J. The probability of backtest overfitting[J]. Journal of Computational Finance, 2017, 20(4): 39-69.